

• 12 Novembre 2024

FORMATION: DataScientest / Data Engineer

PROJET (Nov. 2024): Analyse des Impacts Environnementaux Textiles, avec EcoBalyse v2.4.0

Temps Partiel (9 mois) - jan24_continu_de / cde_projet_ecobalyse





Sommaire

1. CONTEXTE

Ecobalyse Méthodologie / Equipe 2. SOLUTION

Synoptique Architecture

3. TECHNIQUE

Scripts
ML / Comparatifs

4. INTERFACE

Flask Dash





1. CONTEXTE ECOBALYSE

Écobalyse est un outil développé par l'État français pour calculer l'impact écologique des produits textiles (et alimentaires) distribués en France.

Il vise à fournir des informations sur l'empreinte environnementale de ces produits, permettant ainsi aux consommateurs de prendre des décisions plus éclairées et durables sur leurs choix de consommation.

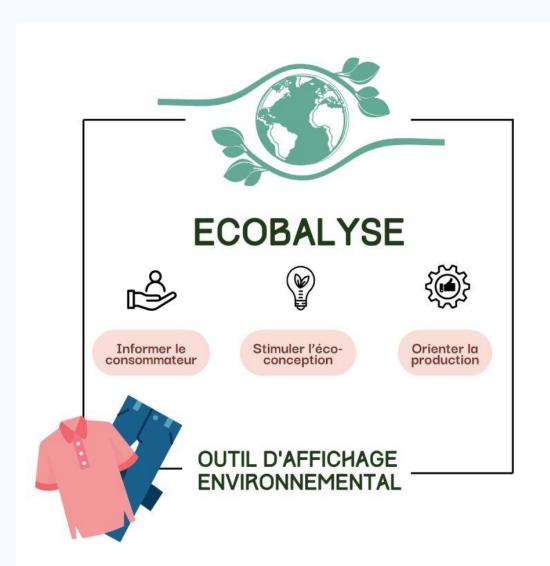
En lien avec les préoccupations actuelles (l'industrie textile est l'une des plus polluantes au monde), **Écobalyse** vise à accélérer la mise en place de l'affichage environnemental, pour favoriser un modèle de production plus durable.

Pour en savoir plus, on peut visiter le site d'Écobalyse ici.

A voir également :

- GitBook Écobalyse
- Explorateur Écobalyse
- Documentation de API Écobalyse

Ademe







1. CONTEXTE METHODOLOGIE

Afin de répondre au cahier des charges du projet, et **révéler le coût environnemental des textiles**, nous avons développé trois programmes distincts, autour de <u>l'API Ecobalyse</u>, qui ont chacun un objectif précis :

- (Ré)Initialiser (./init.sh)
- (Re)Configurer (./setup.sh)
- (Re)Charger (./load.sh)

- Un script qui va initialiser l'environnement et les conteneurs du projet
- Un script qui va extraire, transformer, et traiter les données récupérées
- Un script qui va permettre de visualiser graphiquement les résultats obtenus

La portabilité de l'outil, sur n'importe quel environnement, est assurée par l'utilisation de conteneurs Docker.

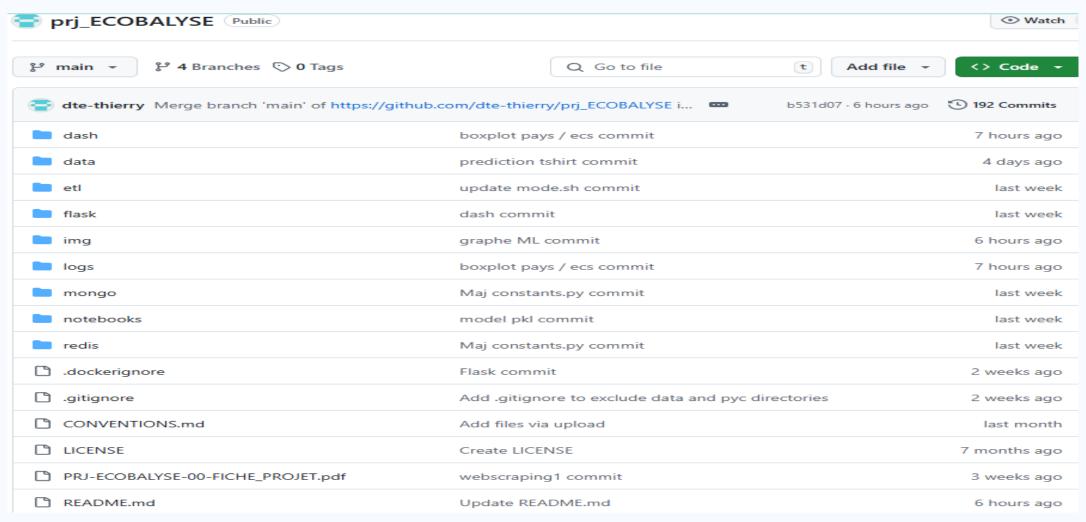






1. CONTEXTE EQUIPE

Un Github a été crée pour le versioning, et permettre à l'équipe d'avoir une même vision de l'avancement du projet.







Sommaire

1. CONTEXTE

Ecobalyse Méthodologie / Equipe 2. SOLUTION

Synoptique Architecture 3. TECHNIQUE

Scripts
ML / Comparatifs

4. INTERFACE

Flask Dash





2. SOLUTION SYNOPTIQUE

Le projet se déroule en quatre étapes :

- 1. Récolte des données
- 2. Architecture et stockage
- 3. Consommation des données
- 4. Mise en production

Ecobalyse DATASCIENTEST - Projet Ecobalyse (Nov. 2024) Solution proposée Ecobalyse DB my_ecobalyse_network (backend) Ecobalyse API learn my_ecobalyse_network (frontend) Flask Flask ETL Dashboard plotly |Dasi my_ecobalyse_network (backend)

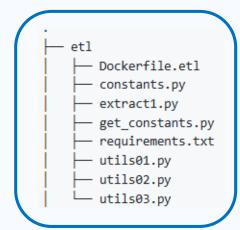
La solution proposée se compose de :

- Un ETL qui a la charge de récupérer les contenus d'Ecobalyse.
- Une base de données MongoDB où sont entreprosées les données récupérées.
- Une base de données **Redis** utilisée comme mémoire cache, afin d'accélérer les requêtes.
- Un dashboard **Dash**, pour la visualisation graphique des données.
- Un Framework Web **Flask** qui sert d'intermédiaire (API) entre le dashboard **Dash**, les bases de données **MongoDB / Redis**, et un modèle scikit-learn entraîné pour des prédictions de Machine Learning.





2. SOLUTION ARCHITECTURE



```
flask
  - Dockerfile.flask
  constants3.py
   get constants3.py
  init flask.sh
   mongo queries.py
  redis queries.py
  - requirements.txt

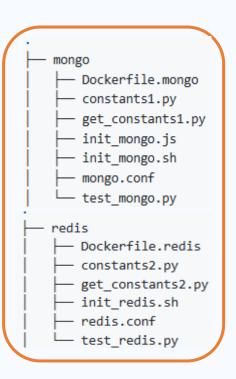
    stylesheets

    listMongoBDD.css

      styles.css
    templates
        bienvenue.html
       index.html

    listMongoBDD.html

   test flask.py
   utils.pv
```



Dossier data > Fichiers params*.txt, paramètres d'entrées nécessaires à l'API Ecobalyse pour retourner un résultat.

Scripts de configuration et d'exécution

```
rj ECOBALYSE
  data
      mongo
      redis
      params01_T-shirt.txt
      params02_Pull.txt
      params03_Pantalon.txt
      params04_Manteau.txt
      params05 Maillot-de-bain.txt
      params06 Jupe.txt
      params07 Jean.txt
      params08_Chemise.txt
      params09_Chaussettes.txt
      params10 Calecon.txt
      params11_Slip.txt
  dag
  dash
  etl
 - flask
 - img
 logs
 - mongo

    notebooks

— redis
  PRJ-ECOBALYSE-00-FICHE PROJET.pdf
  LICENSE
  CONVENTIONS.md
  README.md
  docker-compose.yml

    lisezMoi.txt

 info.sh
 load.sh
  setup.sh
 - init.sh
  starter.sh
```





Sommaire

1. CONTEXTE

Ecobalyse Méthodologie / Equipe 2. SOLUTION

Synoptique Architecture 3. TECHNIQUE

Scripts
ML / Comparatifs

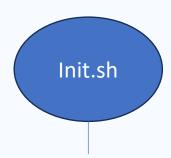
4. INTERFACE

Flask Dash





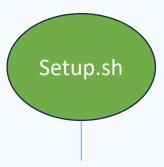
3. TECHNIQUE SCRIPTS



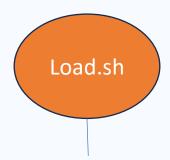
- Nettoie l'environnement pour une nouvelle exécution du setup
- Supprime les images des conteneurs préalablement créés
- Supprime les réseaux préalablement créés pour les échanges entre dockers
- Supprime les données préalablement créées lors de l'exécution du setup

Suppression des anciennes données Redis Suppression des anciennes données MongoDB Suppression de tous les fichiers .json dans le répertoire data Suppression de tous les fichiers .log dans le répertoire logs Mémoire vive disponible : shared buff/cache available total used 7.7Gi 1.0Gi 5.5Gi 2.0Mi 1.1Gi 6.4Gi ØB ØB ØB Espace disque disponible : Size Used Avail Use% Mounted on Filesystem 24G 8.6G 15G 37% / /dev/root

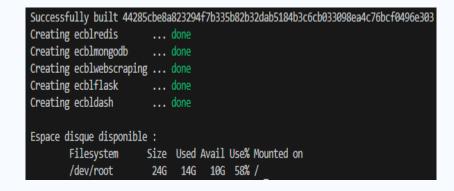
Trois scripts permettent de s'assurer du bon fonctionnement du projet :

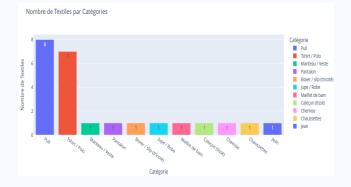


- Supprime les fichiers logs si déjà existants
- Mets en place les conteneurs nécessaires à l'extraction et la transformation des données (ecblwebscraping, ecblmongodb, ecblredis)



- Permet d'avoir une visualisation graphique des données traitées à l'étape précédente via le setup
- Fournit des résultats d'ecoscore basés sur le modèle de Machine Learning choisi pour tester les données fournies en input (24 échantillons en entrée)









3. TECHNIQUE MACHINE LEARNING

Régression Linéaire pour la prédiction de l'ecoscore : ecs Mean Squared Error: 443982.6490384196 R^2 Score: 0.9610584242618365 Coefficient de détermination du modèle sur train: 1.0 Coefficient de détermination du modèle sur test: 0.9610584242618365 10000 8000 vrai valeur 6000 4000 Intercept: 2445.7160216776174 2000 2000 6000 8000 10000 4000 prediction

Utiliser un modèle de régression

Pour prédire une **variable numérique continue** comme ecs , on peut utiliser des modèles tels que la régression linéaire, la régression Ridge, la régression Lasso, ou des modèles plus complexes comme les forêts aléatoires (Random Forest) ou les réseaux de neurones.

Régression Linéaire - Analyse des résultats

Ces résultats montrent que le modèle de régression linéaire semble très performant.

Le modèle de régression linéaire semble bien ajusté aux données, avec une très bonne capacité explicative

• Mean Squared Error (MSE):

Le MSE mesure la moyenne des carrés des erreurs, c'est-à-dire la différence entre les valeurs prédites et les valeurs réelles. Un MSE plus bas indique un meilleur ajustement du modèle. Ici, bien que le chiffre semble élevé, il est important de le mettre en perspective avec l'échelle des données.

R^2 Score:

Le coefficient de détermination (R^2) indique la proportion de la variance des données qui est expliquée par le modèle. Une valeur de (R^2) proche de 1 signifie que le modèle explique presque toute la variance des données. Avec un (R^2) de 0.961, le modèle explique environ 96.1% de la variance, ce qui est excellent.

	valeur estimée	
	2445.716022	intercept
	758.172006	ecs_transformation
	652.936732	ecs_materials
l	425.102037	ecs_transport
ı	412.330324	Masse
	345.437832	numberOfReferences
	178.751264	countrySpinning_TR
	165.414084	Pays_Pays inconnu
	150.323153	ecs_complementsImpacts

Régression Linéaire - Impact des variables - Analyse du résultat

Les coefficients permettent de comprendre l'impact de chaque variable explicative sur la variable cible.

Un coefficient positif indique une relation positive, tandis qu'un coefficient négatif indique une relation négative.

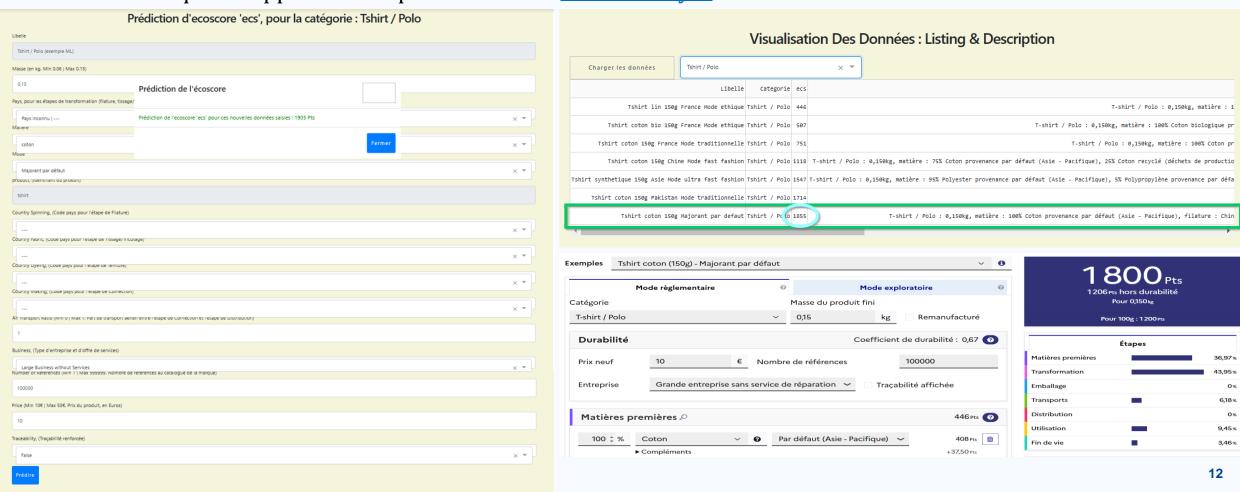
En analysant ces coefficients, on peut identifier quelles variables ont le plus d'influence sur la variable cible et dans quelle direction.





3. TECHNIQUE COMPARATIFS

Suite à l'entrainement de plusieurs modèles de Machine Learning, la Régression Linéaire a été retenue car les résultats fournis sont ceux qui se rapprochent le plus de ceux de <u>l'API Ecobalyse</u>.







Sommaire

1. CONTEXTE

Ecobalyse Méthodologie / Equipe 2. SOLUTION

Synoptique Architecture

3. TECHNIQUE

Scripts
ML / Comparatifs

4. INTERFACE

Flask Dash





4. INTERFACE FLASK (ACCUEIL)

Lancer Flask

• lancer le script ./load.sh -adm pour lancer Flask via un navigateur Web.

Flask

Bienvenue sur la page d'accueil de votre application Flask!

Pour vérifier le bon fonctionnement de votre application, cliquez sur les liens suivants :

<u>Lister les BDD MongoDB</u>

<u>Vérifier le contenu Ecobalyse de la BDD MongoDB</u>

Vérifier le contenu Ecobalyse de la BDD Redis

Pour obtenir quelques métriques sur les données récupérées, cliquez sur le(s) bouton(s) suivant(s) :

Métriques Environnementales

Métriques Économiques

Métriques de Durabilité

Métriques de Transport

Métriques de Traçabilité

Métriques de Transformation

A propos des métriques disponibles :

Métriques Environnementales

Calculer le score environnemental moyen pour chaque catégorie de produit, mode, ou pays

Analyser la distribution des scores environnementaux pour identifier les produits avec des scores particulièrement élevés ou bas

Calculer l'impact moyen des matières premières sur le score environnemental

Métriques Économiques

Calculer le prix moyen des produits par catégorie

Calculer le nombre moyen de références pour chaque mode

Métriques de Durabilité

Calculer la durabilité moyenne des produits en fonction de la matière

Métriques de Transport

Calculer le ratio moyen de transport aérien pour chaque catégorie de produit

Métriques de Traçabilité

Calculer le pourcentage de produits pour lesquels la traçabilité est disponible

Métriques de Transformation

Calculer l'impact moyen de la transformation sur le score environnemental





4. INTERFACE FLASK (MÉTRIQUES – 1A)

Métriques Environnementales

Calcul du score environnemental moyen pour chaque catégorie de produit, mode, ou pays

EcoScore 'ecs' Moyen par Catégorie :

Boxer / slip (tricoté): 414 Pts Caleçon (tissé): 566 Pts Chaussettes: 398 Pts Chemise: 2912 Pts Jean: 5981 Pts

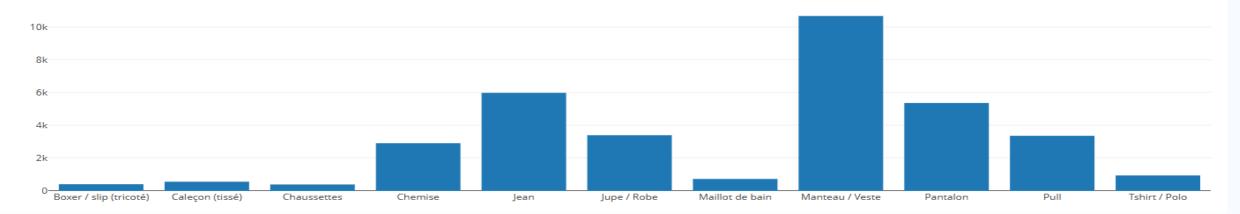
Jupe / Robe: 3400 Pts Maillot de bain: 733 Pts Manteau / Veste: 10668 Pts

Pantalon: 5363 Pts Pull: 3364 Pts Tshirt / Polo: 948 Pts

Lancer Flask

• lancer le script ./load.sh -adm pour lancer Flask via un navigateur Web.

EcoScore Moyen par Catégorie







4. INTERFACE FLASK (MÉTRIQUES – 1B)

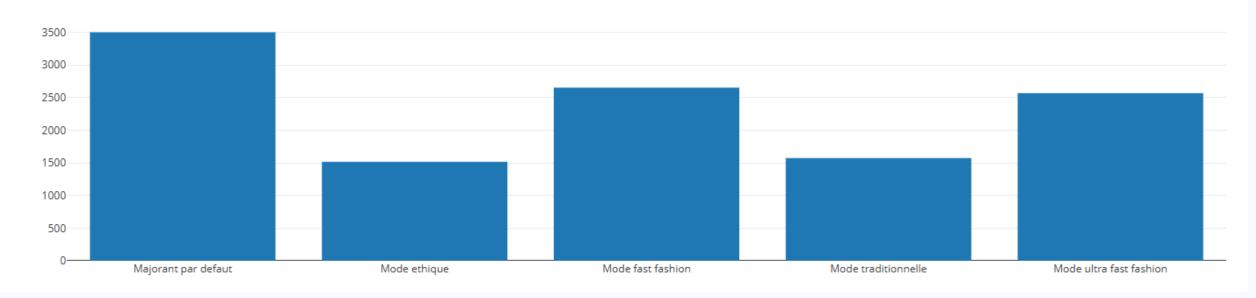
Lancer Flask

• lancer le script ./load.sh -adm pour lancer Flask via un navigateur Web.

EcoScore 'ecs' Moyen par Mode:

Majorant par defaut: 3502 Pts Mode ethique: 1517 Pts Mode fast fashion: 2654 Pts Mode traditionnelle: 1574 Pts Mode ultra fast fashion: 2569 Pts

EcoScore Moyen par Mode







4. INTERFACE FLASK (MÉTRIQUES – 1C)

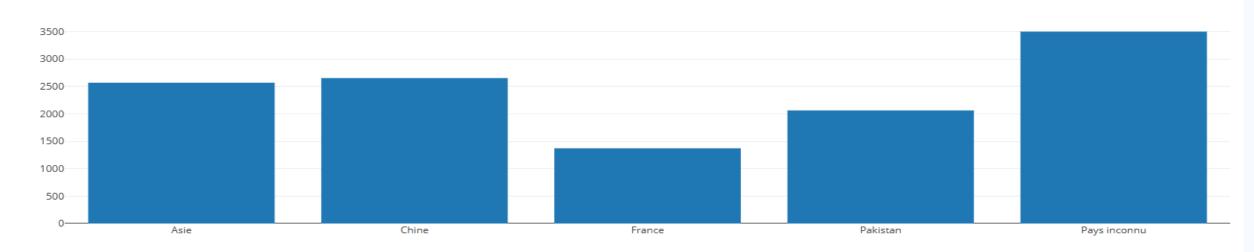
Lancer Flask

• lancer le script ./load.sh -adm pour lancer Flask via un navigateur Web.

EcoScore 'ecs' Moyen par Pays :

Asie: 2569 Pts Chine: 2654 Pts France: 1373 Pts Pakistan: 2064 Pts Pays inconnu: 3502 Pts

EcoScore Moyen par Pays



Temps de chargement des données via MongoDB : 67.74 milliseconds Temps de chargement des données via Redis : 60.83 milliseconds





4. INTERFACE DASH (ACCUEIL)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Dashboard EcoBalyse

(visiter le site EcoBalyse)

A propos ...

Textiles & Environnement

L'industrie textile est l'une des plus polluantes au monde 1, 2, 3, 4, 5.

En lien avec les préoccupations actuelles, et sur la base d'Écobalyse, cet outil propose un comparatif de coûts environnementaux, en vue de favoriser un modèle de production plus durable, et de fournir des recommandations, ou des conseils, sur la manière de réduire l'impact écologique de textiles courants.

En savoir plus :

¹la-goose.com, ²oxfamfrance.org, ³ecologie.gouv.fr, ⁴climateseed.com, ⁵wwf.ch,





Prédiction(s)

Visualisation(s)





4. INTERFACE DASH (VISUALISATIONS - 1)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Visualisation(s) des Données Textiles

Le menu ci-dessous propose de visualiser les données recueillies, depuis le site Ecobalyse. Il permet aux utilisateurs d'explorer les impacts environnementaux des différents produits.

- Listing & Description des Données
- Nombre de Textiles par Catégories
- Distribution cumulée de l'ecoscore 'ecs' par Catégories de Textiles
- o Densité estimée & répartition cumulée de la variable 'ecs'
- Boxplot : Mode / ecs
- Boxplot : Pays / ecs

Retour

© Nov. 2024, DataScientest - Projet Ecobalyse - GitHub : https://github.com/dte-thierry/prj_ECOBALYSE





4. INTERFACE DASH (VISUALISATIONS – 1A)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Visualisation Des Données : Listing & Description

Charger les données Sélectionnez une caté	égorie		
Libelle	Categorie	ecs	
Slip coton 30g Majorant par defaut	Boxer / slip (tricoté)	426	Boxer / Slip (tricoté) : 0,030kg, matière : 100% Coton provenance par défaut (Asie - Pacifique), filat
Calecon coton 40g Majorant par defaut	Caleçon (tissé)	581	Caleçon (tissé) : 0,040kg, matière : 100% Coton provenance par défaut (Asi
Chaussettes coton 40g Majorant par defaut	Chaussettes	414	Chaussettes : 0,040kg, matière : 100% Coton provenance par défaut (Asie - Pacifique), filature : Ch
Chemise coton 250g Majorant par defaut	Chemise	2977	Chemise : 0,250kg, matière : 100% Coton provenance par défaut (Asi
Jean coton 450g Majorant par defaut	Jean	6104	Jean : 0,450kg, matière : 100% Coton provenance par défaut (Asie - Paci
Jupe coton 300g Majorant par defaut	Jupe / Robe	3469	Jupe / Robe : 0,300kg, matière : 100% Coton provenance par défaut (Asi
Maillot de bain polyester 100g Majorant par defaut	Maillot de bain	927	Maillot de bain : 0,100kg, matière : 100% Polyester provenance par défaut (Asie - Pacifique), filat
Manteau coton 950g Majorant par defaut	Manteau / Veste	10948	Manteau / Veste : 0,950kg, matière : 100% Coton provenance par défaut (Asi
Pantalon coton 450g Majorant par defaut	Pantalon	5488	Pantalon / Short : 0,450kg, matière : 100% Coton provenance par défaut (Asi
Pull laine paysane 550g France Mode ethique	Pull	1410	Pull : 0,550kg, matièr
Pull coton bio 550g France Mode traditionnelle	Pull	1543	Pull : 0,550kg, matière : 100% Coton
Pull viscose 550g Chine Mode fast fashion	Pull	2876	Pull : 0,550kg, matière : 70% Viscose provenance par défaut (Asie - Pacifique), 3
Pull coton 550g Pakistan Mode traditionnelle	Pull	3325	Pull : 0,550kg, matière : 100% Coton
Pull coton 550g Chine Mode fast fashion	Pull	4107	Pull : 0,550kg, matière
Pull laine 550g France Mode ethique	Pull	4524	Pull : 0,550kg, matière : 100% Laine p
Pull polyester 550g Asie Mode ultra fast fashion	Pull	5248	Pull : 0,550kg, matière : 100% Polyester provenance par défa
Pull coton 550g Majorant par defaut	Pull	6483	Pull : 0,550kg, matière : 100% Coton provenance par défaut (Asie - Pacifique), filat
Tshirt lin 150g France Mode ethique	Tshirt / Polo	446	T-shirt / Polo : 0,150kg, m
Tshirt coton bio 150g France Mode ethique	Tshirt / Polo	507	T-shirt / Polo : 0,150kg, matière : 100% Coton bio
Tshirt coton 150g France Mode traditionnelle	Tshirt / Polo	751	T-shirt / Polo : 0,150kg, matière : 100
Tshirt coton 150g Chine Mode fast fashion	Tshirt / Polo	1118	T-shirt / Polo : 0,150kg, matière : 75% Coton provenance par défaut (Asie - Pacifique), 25% Coton recyclé (déchets de
Tshirt synthetique 150g Asie Mode ultra fast fashion	Tshirt / Polo	1547 T	-shirt / Polo : 0,150kg, matière : 95% Polyester provenance par défaut (Asie - Pacifique), 5% Polypropylène provenanc
Tshirt coton 150g Pakistan Mode traditionnelle	Tshirt / Polo	1714	
Tshirt coton 150g Majorant par defaut	Tshirt / Polo	1855	T-shirt / Polo : 0,150kg, matière : 100% Coton provenance par défaut (Asie - Pacifique), filat



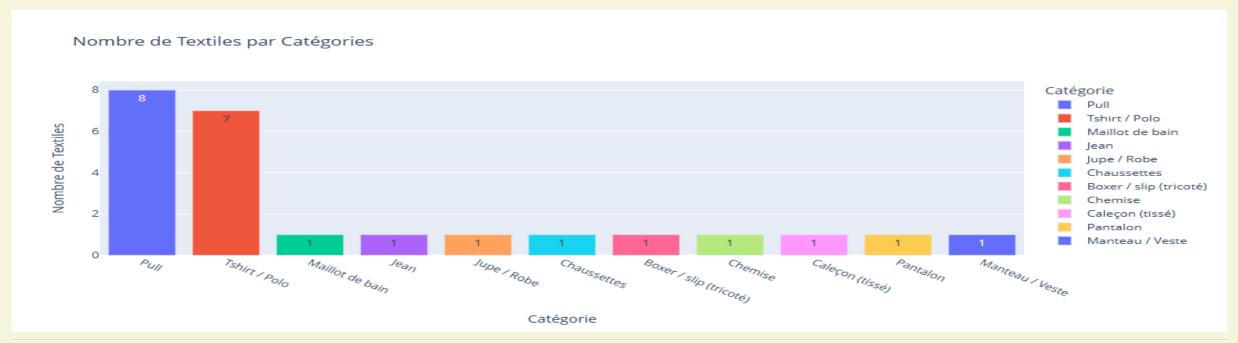


4. INTERFACE DASH (VISUALISATIONS – 1B)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Nombre de Textiles par Catégories



Nota:

====

Par défaut, l'Explorateur Ecobalyse propose un jeu de données très restreint.

Ce jeu de données peut être insuffisant, pour entraîner correctement un modèle de Machine Learning.



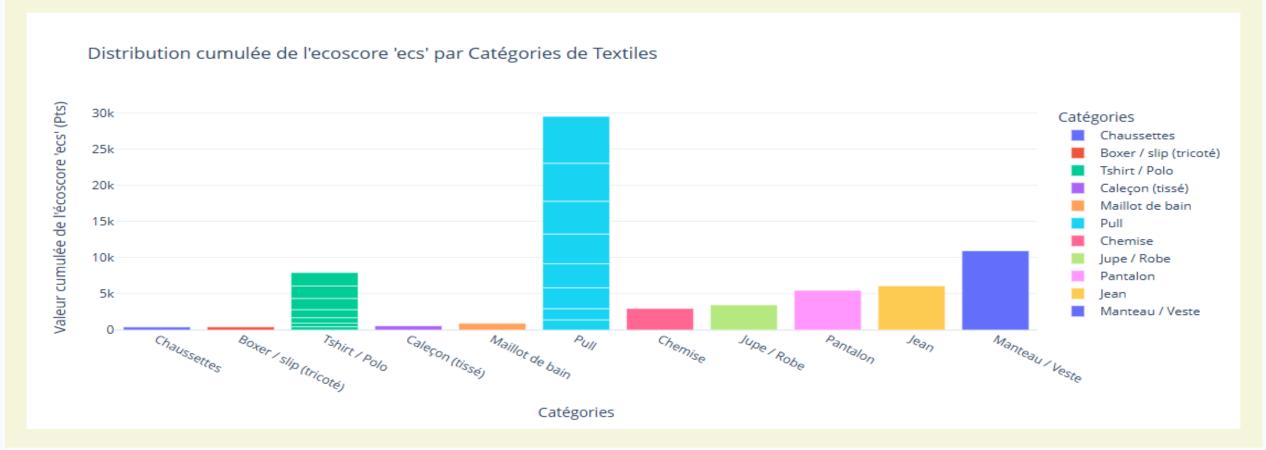


4. INTERFACE DASH (VISUALISATIONS – 1C)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Distribution cumulée de l'ecoscore 'ecs' par Catégories de Textiles



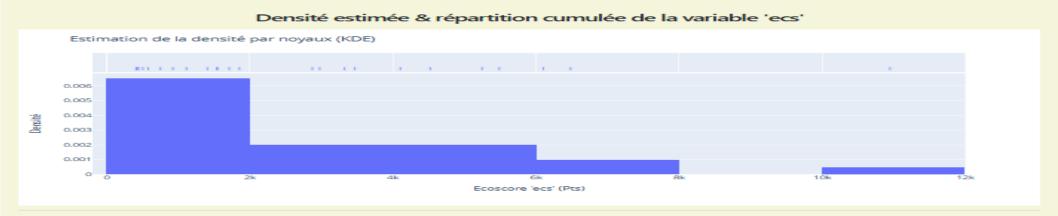




4. INTERFACE DASH (VISUALISATIONS – 1D)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.



Le graphique ci-dessus montre : la distribution, et la densité estimée de la variable 'ecs'.

On observe une forte densité, et une concentration élevée de valeurs, autour d'un 'ecoscore' de 2000 Pts.

Ce qui signifie qu'une grande majorité de textiles, dans ce jeu de données, a un impact environnemental <= 2000 Pts.



Le graphique ci-dessus montre : la répartition cumulée empirique (ECDF) de la variable 'ecs'. la **courbe ECDF** (Empirical Cumulative Distribution Function) de distribution cumulative, commence à zéro et augmente par paliers pour atteindre 1.0 à droite. Cette courbe montre la proportion cumulative de l'ecoscore 'ecs'.

Les paliers significatifs se trouvent autour de 2500, 5000, 7500, et juste avant 10000. Une grande proportion des observations a une valeur 'ecs' inférieure ou égale à 2500 Pts.

La courbe atteignant 1.0, indique que toutes les observations sont incluses à la fin.

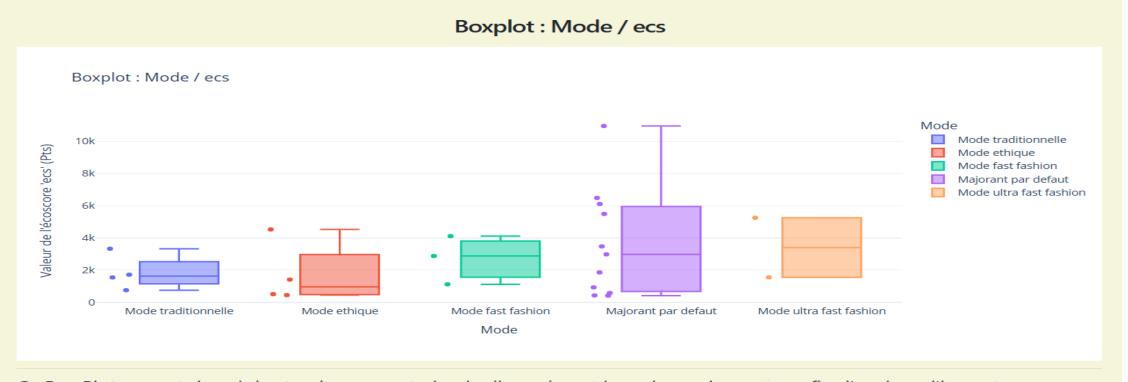




4. INTERFACE DASH (VISUALISATIONS – 1E)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.



Ce Box Plot permet de voir les tendances centrales, la dispersion et les valeurs aberrantes, afin d'analyser l'impact environnemental des différents types de modes.

La ligne horizontale à l'intérieur de chaque boîte représente la **médiane** des valeurs 'ecs' pour chaque catégorie. Les extrémités de la boîte représentent le **premier quartile (Q1)** et le **troisième quartile (Q3)**.

La distance entre **Q1** et **Q3**, l'**étendue interquartile (IRQ)** donne une idée de la variabilité des valeurs 'ecs' pour chaque type de mode.

Les points situés en dehors des moustaches sont des valeurs aberrantes (outliers).

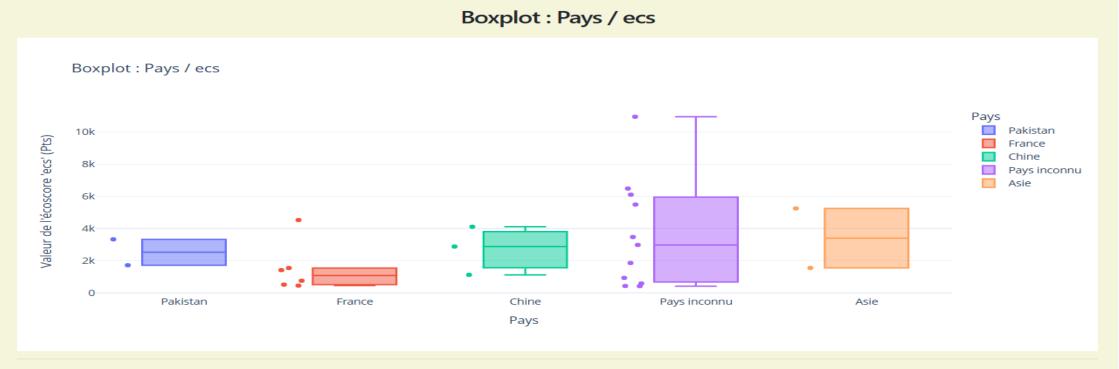




4. INTERFACE DASH (VISUALISATIONS – 1F)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.



Ce Box Plot permet de voir les tendances centrales, la dispersion et les valeurs aberrantes, afin d'analyser l'impact environnemental des différents types de pays.

La ligne horizontale à l'intérieur de chaque boîte représente la **médiane** des valeurs 'ecs' pour chaque catégorie. Les extrémités de la boîte représentent le **premier quartile (Q1)** et le **troisième quartile (Q3)**.

La distance entre **Q1** et **Q3**, l'**étendue interquartile (IRQ)** donne une idée de la variabilité des valeurs 'ecs' pour chaque type de pays.

Les points situés en dehors des moustaches sont des valeurs aberrantes (outliers).





4. INTERFACE DASH (PREDICTIONS - 2)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

Prédiction(s) pour les catégories de textiles

Le menu ci-dessous permet de prédire l'impact environnemental de produits non couverts par l'API d'Ecobalyse.

Pour chaque catégorie, le modèle utilisé de prédiction en Machine Learning est : la régression linéaire.

Les paramètres à saisir, pour de nouvelles données textiles, sont :

Masse, Matière, Mode, Pays, countrySpinning, countryFabric, countryDyeing, countryMaking, airTransportRatio, business, numberOfReferences, price, traceability.

La variable estimée par prédiction (indépendamment d'un calcul via l'API Ecobalyse) est l'écoscore global ('ecs') des impacts environnementaux.

- Boxer / slip (tricoté)
- Caleçon (tissé)
- Chaussettes
- Chemise
- Jean
- Jupe / Robe
- Maillot de bain
- Manteau / Veste
- Pantalon
- Pull
- Tshirt / Polo

Retour



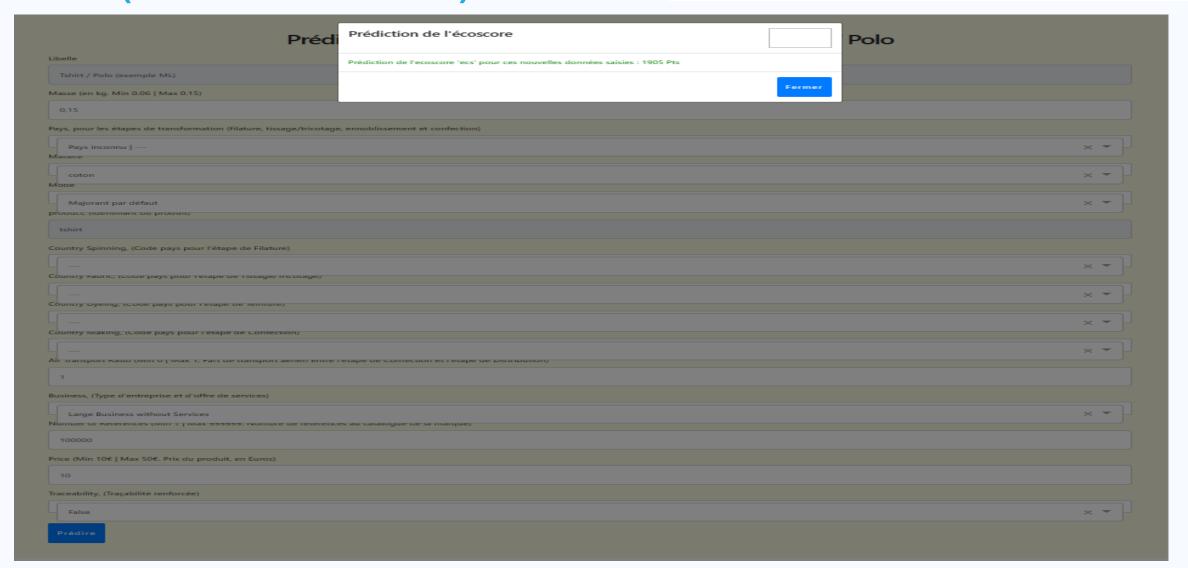




4. INTERFACE DASH (PREDICTIONS – 2A)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.







4. INTERFACE DASH (PREDICTIONS – 2B)

Lancer Dash

• lancer le script ./load.sh pour lancer Dash via un navigateur Web.

